



# 面向目标的传输调度： 基于结构引导的统一双策略深度强化学习方法

- 核心创新：  
应用驱动目标转向
  - 理论突破：  
单调性/渐近凸性证明
  - 算法设计：  
SUDO-DRL统一双策略框架
  - 实验验证：  
40设备20信道大规模场景收敛性
- 
- 传统DRL：  
40设备场景不收敛
- SUDO-DRL：性能提升30%-40%


作者：Jiazheng Chen, Wanchun Liu\* (通讯作者)






## 多设备多信道系统

在多设备多信道无线通信系统中， $N$ 个边缘设备共享 $M$ 个有限衰落信道 ( $M < N$ )。研究的核心问题是寻找最优调度策略 $\pi$ ，以最小化所有设备的长期期望总成本。在远程状态估计场景下，这等同于最小化与信息年龄 (AoI) 相关的估计状态均方误差 (MSE)

- **高维状态空间：**必须实时跟踪每个设备的AoI和信道状态，复杂度随设备数量呈指数级增长
- **庞大的动作空间：**对于 $N$ 设备 $M$ 信道，动作数为 $N! / (N-M)!$ 。  
在10设备5信道场景下，动作数已达30,240个，传统MDP求解器完全失效
- **目标转向：**从单纯的传输比特转向满足特定应用需求 (Remote State Estimation)



# 现有方法的 局限性与研究空白



## 1. 传统方法:

启发式方法（如Whittle's Index）虽快但非最优；动态规划（值迭代/策略迭代）面临“维度灾难”

## 2. 标准DRL算法:


- 离策 (Off-Policy) 如DQN/DDPG: 虽样本效率高，但在大型动态系统中训练极不稳定，40设备场景下无法收敛-
- 同策 (On-Policy)  
如PPO/TRPO: 稳定性好但样本效率极低，数据利用率差，易陷入局部最优

## 3. 理论结合缺失:

现有研究多采用“暴力优化”，未深入挖掘AoI状态最优点函数的数学性质（如单调性、凸性），导致在大规模系统（20-40个传感器）中性能严重下降或不收敛

核心思想：结合PPO在线策略稳定性与SAC离线策略效率，用理论结构属性指导训练

1. 理论属性推导：证明V函数单调性与渐近凸性
2. 结构评分机制：转化为CM（单调性）、CC（凸性）、AM（策略单调性）评分
3. 统一双损失函数：通过剪刀,  $\beta_2$ 桥接在线与离线更新
4. 结构引导回放池：基于评分选择性存储与优先级采样



结构评分分布





1. V函数单调性：价值函数随AoI和信道状态增加单调递增




2. 漸近凸性：传输调度领域首次证明V函数随AoI状态漸近凸性



3. 策略单调性：最优策略关于信道状态具有单调性



4. 漸近贪婪结构：共址设备AoI极大时最优策略倾向强制调度（预训练理论依据）



## CM Score (Critic-Monotonicity)

评估Critic网络预测的V值是否随Aoi增加，若违反则产生惩罚项：

$$\check{y}_{Aoi} = \max(0, v(s; v) - v(\hat{s}_{(n)}; v))$$

## CC Score (Critic-Convexity)

评估V函数的二阶差分是否符合凸性：

$$\hat{c}_{Aoi} = \max(0, 2v(s; v) - (v(\hat{s}_{(n)}; v) + v(\hat{s}_{(n)}; v)))$$

## AM Score (Actor-Monotonicity)

评估Actor网络的动作选择是否符合信道单调性逻辑，评分决定数据是否进入回放池及采样优先级



数学证明

# 统一双损失函数

## 1. Critic统一损失:

$$L_{\text{SUDO}}(v) = L_{\text{On}}(v) + \beta_1 L_{\text{Off}}(v) + \text{Structural Penalties}$$

其中 $L_{\text{On}}$ 处理当前轨迹TD误差， $L_{\text{Off}}$ 处理回放池历史数据TD误差

## 2. Actor统一损失:

$$L_{\text{SUDO}}(\phi) = L_{\text{On}}(\phi) + \beta_2 L_{\text{Off}}(\phi)$$

结合PPO裁剪损失（稳定性）与SAC风格离线策略梯度（效率），解决传统离策方法大规模调度发散问题

公式推导



## 1. 选择性存储:

仅存储结构评分 (CM, CC, AM) 超历史平均的轨迹，确保回放池为高质量样本



## 2. 优先级采样:


采样概率Pb由结构评分和新近度决定，公式为Pb

$$Pb \approx (pb \geq varrho^b) / \sum (pb \geq varrho^b)$$



## 3. 漸近贪婪预训练:

前 $10 \times N$ 回合用定理 5 贪婪结构指导动作，收敛速度提升约40%



# 实验设置：远程状态估计仿真

MORANDI



## 规模覆盖：

从10设备5信道扩展至40设备20信道（超大规模）



## 信道模型：

i.i.d.块衰落信道，量化为5级状态，丢包率范围0.01至0.2




## 神经网络：

Actor和Critic均为3层隐藏层的全连接网络



## 训练参数：

10,000训练回合，每回合128步；  
 $\gamma=0.99$ ，学习率Critic=0.001, Actor=0.0001



硬件支持：NVIDIA RTX 3060Ti GPU。  
评估指标侧重于平均总MSE成本和收敛速度

Hyperparameters	Value
Discount factor, $\gamma$	0.99
Clipping parameter, $\epsilon$	0.2
Clipping parameter, $\epsilon$	0.9
Unified loss weight, $\beta_1, \beta_2$	0.9
Replay buffer, R	200
Pre-training episodes	$10 \times N$




## 性能对比：SUDO-DRL的卓越表现

1. 小规模场景 (10, 5): SUDO-DRL成本为85.52，接近专门优化的SE-DDPG (77.14) , 远优于PPO (119.63) 。
2. 大规模场景 (30, 15) 及以上: 所有离策算法 (DDPG变体) 均宣告失败 (无法收敛) 。

SUDO-DRL不仅成功收敛，且性能比PPO提升了30%-40%。

3. 鲁棒性: 在不同参数设置下 (Para. 1-16) , SUDO-DRL始终保持最低的MSE成本，证明了其在复杂、动态无线环境下的稳健性。



Doc Table 2			
Scale (N, M)	PPO	SUDO-DRL	DDPG Variants
(10, 5)	119.63	85.52	77.14-89.26
(20, 10)	569.96	370.63	357.14 (Partial Fail)
(30, 15)	900.71	518.03	Failed (-)
(40, 20)	1291.54	994.80	Failed (-)

# ○ 消融研究与收敛效率分析

MORANDI

1

## 结构引导的作用：

SUDO-DRL在200回合内达到100分凸性评分(CC Score)，PPO徘徊80分以下，结构引导强制模型学习正确物理规律

2

## 预训练的价值：

全功能版本比无预训练版本收敛速度快40%，预训练使初始MSE成本从800+降至700以下

3

可扩展性突破：SUDO-DRL是首个在40设备20信道规模下保持高性能且稳定收敛的DRL调度算法，填补大规模目标导向通信技术空白



200  
100



80  
80



40%




800+



700

40设备20信道

SUDO-DRL与PPO的CC Score收敛情况



# 结论与贡献总结

MORANDI

1. 理论突破：首次证明AoI调度中价值函数的渐近凸性，利用单调性构建约束学习框架
2. 算法创新：提出统一双策架构，兼顾PPO稳定性与SAC效率
3. 性能飞跃：相比PPO，系统性能提升25%-45%，收敛速度提升40%
4. 大规模适用性：解决40台设备维度灾难，实现理论最优与计算可行平衡
5. 未来研究：探索多跳网络或异构业务流应用

